

Cahier de Charge – Application OCR vers XML

1. Objectif

Développer une application permettant d'uploader une image ou un PDF, d'extraire son contenu via OCR et de générer un fichier XML compatible avec un moteur de génération de rapports PDF.

2. Fonctionnalités principales

- Upload de fichiers (PDF, JPG, PNG)
- Extraction du texte via OCR
- Analyse et structuration des données
- Génération automatique du XML
- Téléchargement du XML ou génération PDF

3. Architecture technique

Frontend : Angular

Backend : Node.js ou PHP

OCR : Tesseract ou API externe

4. Workflow

1. Upload fichier
2. OCR extraction
3. Analyse du texte
4. Mapping vers XML
5. Génération du fichier XML
6. Téléchargement ou génération PDF

5. Structure XML

Le XML est structuré avec les sections suivantes :

- report : racine
- db : sources de données
- general : configuration

- header : entête
- detail : données
- summary : totaux
- footer : pied de page

6. Objets XML

Chaque objet contient : position, taille, texte, type, police, alignement, etc.

7. Contraintes

- Précision OCR élevée
- XML valide
- Temps de traitement rapide

8. Evolutions

- Editeur visuel XML
- Support multi-template
- Intelligence artificielle pour reconnaissance avancée